72 小时实验：实时互动场景产品

项目背景

请你作为架构师，为一款结合实时语音、角色表演以及图片和视频等多模态内容的产品做方案设计和 MVP实现。

请从零实现一个移动端网页适配优先的互动场景。不是传统的聊天消息列表：用户面对的是一个处于具体环境中的角色，可以通过文字或语音和角色互动；角色会说话、改变表情或动作，并根据交流过程触发场景演出。

时间和工具

- 提交窗口为收到题目后的 72 小时，建议在 README 中记录大致投入时间。
- 可以并鼓励使用 Codex、Claude Code、Cursor、v0 等 AI 编程工具。
- 可以自由选择前端、后端、模型、实时音频和媒体技术方案。
- 不要求训练或微调模型。

基础场景

你可以自行设计一个简短场景，也可以使用下面的故事种子：

> 暴雨后的夜晚，用户在一家即将打烊的咖啡馆遇到 Mira。Mira 是一名 26 岁的旅行摄影师，穿着琥珀色雨衣，戴着银色星星发夹。她似乎在等待某个人，但不愿直接说出原因。

体验应使用原创成年角色。剧情创作本身不需要复杂，能够支撑一次连续的 3–5 分钟互动即可。

核心体验

1. 页面

- 页面以场景和角色为视觉主体，不使用传统聊天消息列表作为主要界面。
- 包含背景、角色、字幕区域以及文字和语音交互入口。
- 适配移动端，桌面端可以正常体验。
- 至少呈现以下角色状态：待机、倾听、思考、说话。
- 用户能够从画面中感知角色当前所处的状态。

2. 文字和语音互动

- 用户可以输入文字与角色交流。

最终版功能对照（题目 × 小蠢 XiaoChun）

feature/interactive-scene-flow

HEAD 2d71fa2（main..HEAD 154 提交，2026-10-29 04:10）；基线 main@524af1c

共 106 条：已有 78 / 替代满足 9 / 部分 9 / 无 7 / 说明性 3

main 为：已有 34 / 部分 39 / 无 30

已迭代 88 条（其中状态升级 53 条，页边 ↑ 标注）

已迭代 = 相对 main 有改进/新增

已有 替代满足 部分 无 替代满足=未按字面实现，但以其它方案满足该条意图

实测：vitest 63 文件/549 项全过 · tsc 0 错误 · i18n zh/en/ja 各 822 key · check:cjk 0

docs/coding-test/README.md、AI_USAGE.md 已按模板填写（含 4K/2K 演示视频链接）

部分 已迭代 基于既有 XiaoChun(main 524af1c)迭代 154 提交；README 开头已如实声明复用

已有 已迭代 ↑无→已有 README §8：每日首末提交跨度−凌晨睡眠 8h−休息 2h，合计约 35.5h

说明 已迭代 AI_USAGE.md 已写：Gemini 3.8 Flash 主力编码 / Grok+Grok Bot 调研核对 / MiniMax 打杂

说明 说明性条款，无需实现

说明 说明性条款，无需实现

已有 已迭代 ↑无→已有 自设场景：Act 0「序章・初遇小蠢」后台抓包→选语言→检查仪容→换装→选场景→暗号→选大脑

已有 已迭代 ↑部分→已有 原创 VRoid 成年角色(README 已写明)；Act 0+自由聊天可撑 3–5 分钟

已有 已迭代 电影遮幅/转场/调色 + ChatBubble 字幕条 + 选项卡；无消息列表

已有 已迭代 背景(void/beach3d/线稿)+角色+字幕条+文字输入+VoicePill 麦克风

已有 已迭代 手机：选项卡堆叠在字幕条上方；PC：右侧；三语界面 822 key 对齐

已有 已迭代 ↑部分→已有 四状态齐：新增倾听姿态(listening.vrma 动捕)+TurnState 状态机

已有 已迭代 ↑部分→已有 倾听/思考/说话均有姿态+气泡+VoicePill 波形；忙时按钮变停止

已有 已迭代 输入框加 IME 合成保护/防高度塌陷；按钮随 TurnState 变发送/停止

- 用户可以通过麦克风与角色交流。
- 角色使用语音回复，并同步显示字幕。
- 一次会话中可以连续完成多轮互动。
- 语音可以采用端到端实时语音模型，也可以采用 STT、语言模型和 TTS 组合方案。

部分 已迭代 麦克风：VAD 分句→云端 Whisper/本地 SenseVoice 转写进输入框；仍需手动发送

已有 已迭代 Edge TTS 经 /api/tts(R2 缓存)；语音随台词文字自动选 zh/ja；打字机字幕出声才显示

已有 已迭代 剧情历史 StoryHistory + 生成器保留最近 12 条上下文

已有 已迭代 STT 改为 云端 Whisper(Workers AI)/自定义 OpenAI 兼容/本地 SenseVoice 可选

3. 语音打断

当角色正在说话时，用户应当能够开始新的语音输入并打断角色。

已有 已迭代 ↑部分→已有 聊天模式：Silero VAD speech_start→stopSpeaking→倾听(Act 0 不开放打断)

打断发生后：

- 当前角色语音立即停止。
- 当前尚未完成的回复被取消或失效。
- 尚未播放的字幕、动作和媒体事件不会继续出现。
- 页面切换到倾听状态，并开始处理用户的新输入。
- 上一轮迟到的网络响应不会覆盖当前状态或重新开始播放。

已有 已迭代 ↑部分→已有 stopSpeaking()=chatDirector.stop()+bubbleTracker.hide()，UI 有停止钮

已有 已迭代 utterance id + guardedStatus 防僵尸气泡；故事引擎 executionSequence

已有 已迭代 bubbleTracker.hide()+guardedStatus 保证被打断后字幕/动作不再冒出

已有 已迭代 ↑部分→已有 speech_start 即切倾听姿态并开始 2-pass 识别新输入(仍需手动发送)

已有 已迭代 新增 currentTurnId 防 STT 幽灵文本、motion play race token

可以使用自动语音活动检测，也可以设计明确的按住说话或点击打断交互。请在 README 中说明选择该方式的原因。

已有 已迭代 ↑部分→已有 README §3 已写：VAD 自动打断为主 + 按住说话 + ■停止，及选择原因

4. 角色和场景驱动

角色回复除文本或语音外，还应能够驱动画面变化。请设计一种结构化的角色或场景指令，表达例如：

- 当前情绪
- 表情或姿势
- 动作
- 场景或镜头变化
- 特效
- 可选剧情分支
- 图片或视频事件

已有 已迭代 ↑部分→已有 story/schema.ts(zod) 拍子协议驱动 Act 0 全部演出；自由聊天仍为纯文本+EMAGE

已有 已迭代 ↑部分→已有 9 种基础情绪(含 happy/angry)+强度+4 种微反应

已有 已迭代 ↑部分→已有 actor.expression + leadInMotion/motion；camera.shot

已有 已迭代 ↑部分→已有 leadInMotion/motion→MOTION_CATALOG 35 个 VRMA；说话时保留拍子动作(preserveMotion)

已有 已迭代 ↑部分→已有 景别+运镜：slow_push_in/orbit_to_front/dutch_tilt/hero_spiral；结束缓回默认视角

已有 已迭代 ↑无→已有 白闪/黑场/眨眼真转场、3 种调色、风力 0–3、程序化 BGM/SFX

已有 已迭代 ↑无→已有 选项分支 + branch/variants(第5拍按所选场景改写) + change_lang

替代满足 ↑无→替代满足 题目字段为"例如"；视觉事件由 effect/scene/camera 字段承担，至少项均满足

不限定具体协议格式。至少实现：

- 3 种可以辨认的情绪或表情；
- 2 种非说话动作或视觉状态；
- 1 次背景、镜头或环境变化；
- 1 个由当前对话内容触发的明显视觉事件。

已有 已迭代 ↑部分→已有 Act 0：angry+一怔、shy+脸红、playful+眯眼、happy 等，阻尼过渡

已有 已迭代 倾听动捕/思考/待机风味；剧情动作+换装 outfitShowcase 展示动作

已有 已迭代 ↑部分→已有 void→海边/线稿场景白闪切换；海边昼夜从"现在−12h"扫到此刻再跟随真实时间

已有 已迭代 ↑无→已有 用户选语言/衣服/场景即触发换语言、换装+展示动作、白闪换场景；输入→LLM 拍子

视觉事件不能只按照固定计时器播放，需要和当前回复、角色状态或剧情节点有关。

已有 已迭代 ↑无→已有 视觉事件由当前拍/用户选择/输入触发，执行序号防过期，非计时器

5. 一种多模态表现能力

从下面选择至少一种集成到完整体验中：

- Live2D、Rive、Spine、序列帧或其他角色动画；
- 由角色状态驱动的 MP4/WebM 剧情片段；
- 根据当前对话动态生成的场景图片；
- 根据当前对话或图片生成的短视频。

使用视频时，需要处理加载、播放结束和用户中途打断。使用生成式媒体时，需要向用户呈现生成中的状态，并处理失败情况。

已有 已迭代 选 3D 角色动画：VRM+35 VRMA+EMAGE 音频手势+表情口型

已有 已迭代 VRM 动画：preserveMotion 与 EMAGE 无缝接力、手指 0.34s 微淡入

替代满足 ↑无→替代满足 四选一：已选 3D 角色动画(VRM+VRMA+EMAGE)，不必再做剧情视频

替代满足 ↑无→替代满足 四选一：已选 3D 角色动画，不必再做场景生图

替代满足 ↑无→替代满足 四选一：已选 3D 角色动画，不必再做生成短视频

替代满足 已迭代 ↑部分→替代满足 用的生成内容是 LLM 剧情拍/回复：生成中有思考动作+按钮禁用，失败走兜底拍

6. 可运行的前后端闭环

- 页面、服务端和模型调用可以完整运行。
- 会话内的角色和场景状态能够连续变化。
- 对模型超时、断线、音频或媒体加载失败提供基本反馈和恢复方式。
- 快速连续输入或打断时，不应播放已经失效的回复。
- 提供无需私人 API 密钥也能查看核心流程的方式，例如 Mock 模式或录制回放模式。

已有 已迭代 Cloudflare Worker：SSR+/api/tts+/api/stt；pnpm run deploy 上线 xiaochun.firetable.tech

已有 已迭代 ↑部分→已有 剧场内角色/表情/镜头/场景/昼夜按拍连续变化；换装/场景持久化

已有 已迭代 ↑部分→已有 STT 熔断回落本地；剧情 LLM 6.5s 兜底拍；TTS 失败只出字幕；GPU 上下文 pagehide 释放

已有 已迭代 加固：guardedStatus、turn epoch、play race token

已有 已迭代 Act 0 = 零 Key Mock 演示(脚本化+程序化音频)；大脑默认端侧 WebLLM 无需 Key

可选扩展

完成核心体验后，可以根据时间选择任意方向继续探索。以下内容均不是必须项。

实时语音

- 自动检测用户开口并完成自然打断；
- 区分真正的打断与“嗯”“对”等附和；
- 回声消除，避免角色听到自己的声音；
- 流式字幕；
- 展示语音首包延迟或关键阶段耗时；
- 断线重连和会话恢复。

已有 已迭代 ↑部分→已有 Silero VAD v5 自动检测开口并打断

部分 已迭代 新增 RMS 门限(bargeInRms)+Silero 置信度；仍无语义级附和判断

已有 已迭代 ↑部分→已有 浏览器 AEC+播放期漏音门控(RMS 0.08)+250ms 冷却；静音帧跳过 VAD 推理

已有 已迭代 ↑部分→已有 ChatBubble 流式打字机+多段播放；STT 2-pass 流式文字

部分 已迭代 开发抽屉语音卡片显示识别耗时/时长/RMS；无面向用户的首包延迟

部分 已迭代 STT 熔断自愈、LLM 超时兜底；无 WS 重连

角色表演

- 口型同步；
- 眨眼、呼吸、视线和待机行为；
- 动作优先级、中断和自然衔接；
- 情绪之间的平滑过渡；
- 音频驱动的角色动作；

已有 已迭代 说话时表情自动让位给口型(speechMouthDucking)

已有 已迭代 倾听注视(92% 直视)、眨眼睡眼动作、待机风味调度

已有 已迭代 自适应淡入 0.75–1s、手指 0.34s 微淡入、race token、preserveMotion 接力

已有 已迭代 ↑部分→已有 expressionController 阻尼(7.5)平滑切换情绪

已有 已迭代 EMAGE 语音→全身手势；自定义动作播完由 EMAGE 无缝接管

- 配置驱动的角色资源和动作系统。

已有 已迭代 ↑部分→已有 MOTION_CATALOG 35 动作配置驱动；管线参数收进 APP_CONFIG.motionPipeline

视频演出

- 视频片段预加载和无黑屏切换；
- 字幕、语音和视频时间线同步；
- 全屏剧情片段和常驻角色之间的衔接；
- 视频加载失败后的动画或静态画面降级；
- 透明视频、遮罩或分层合成。

无 无视频能力

无 无视频能力

替代满足 已迭代 ↑无→替代满足 无视频，但剧情拍用 letterbox 电影模式驱动同一常驻 3D 角色，结束镜头平滑回位

无 无视频能力

无 无视频能力

生成式图片和视频

- 使用角色参考图生成新的剧情场景；
- 保持人物外观、服装和环境的连续性；
- 在关键剧情节点生成短视频；
- 生成期间使用现有角色动画承接体验；
- 缓存和复用已经生成的内容；
- 对明显失败的生成结果进行检测或重新生成。

无 无生成式媒体

替代满足 已迭代 ↑无→替代满足 同一 VRM 模型天然保持外观；换装跨 Act 0/场景持久化，环境按时间连续

无 无生成式媒体

替代满足 ↑无→替代满足 LLM 生成回复期间播放 thinking.vrma 思考动作承接，不冷场

无 无生成式媒体

替代满足 已迭代 ↑无→替代满足 对生成的剧情拍做检测：jsonrepair+zod 校验，字段缺失补默认，解析失败换兜底拍

工程扩展

- 支持替换不同的模型或媒体 Provider；
- 统一传递和处理取消信号；
- 记录一次互动中的主要状态事件；
- 支持会话回放或问题诊断；
- 添加自动化测试；
- 给出延迟、错误和模型调用情况的简单观测页面。

已有 已迭代 LLM/STT/TTS 均可换 Provider(含 MiniMax/Groq/Workers AI)

部分 已迭代 RunChatOptions.signal、ttsClient signal、STT 超时；WebLLM 不可取消

部分 已迭代 TurnState 变更事件+剧情 history+语音记录；无持久日志

部分 已迭代 DevDrawer 语音会话回放(音频+转写)；无完整会话回放

已有 已迭代 vitest 63 文件/549 项全过；tsc 0 错误；check:i18n 822×3；check:cjk 0

部分 已迭代 DevDrawer 增语音分析卡/动作面板；仍仅 dev

技术和素材

- 可以使用任何合理的开源库、商业 API 或本地模型。
- 可以使用自制、开源或 AI 生成的视觉和音频素材。
- 请在 README 中注明主要第三方服务和素材来源。
- 请勿在仓库中提交 API 密钥或其他私人凭证。
- 如果某项外部服务无法提供公开演示，请通过 Mock 或回放方式保证项目仍可体验。

已有 three-vrm、WebLLM、onnxruntime(Silero/SenseVoice/EMAGE)、Tone.js、Workers AI

已有 已迭代 VRoid 模型、VRMA 大多转换自 Adobe 开放动作库(Mixamo)、程序化场景/BGM/音效

已有 已迭代 README §5 列出开源库/服务/模型/素材；VRMA 来源写明为 Adobe Mixamo 转换

已有 .gitignore 忽略 *.local/.tauri；.env.example 无密钥；扫描无命中

已有 已迭代 ↑部分→已有 Act 0 Mock 序章+离线兜底拍+STT 本地兜底；无录制回放

交付内容

请提交以下内容：

1. 源代码仓库。
2. 可访问的演示地址，或清晰的本地启动说明。
3. 一条命令完成本地启动；如果无法做到，请确保完整启动过程可在 15 分钟内完成。
4. 一段 3–5 分钟的演示录屏，展示：
    - 文字或语音互动；
    - 角色状态和画面变化；
    - 在角色说话时成功打断；
    - 所选择的动画、视频或生成媒体能力；
    - 至少一种失败或降级状态。
5. README，内容包括：
    - 系统结构和主要模块；
    - 语音交互与打断流程；
    - 角色和场景指令的设计；
    - 使用的模型、媒体方案和主要第三方服务；
    - 关键技术选择与取舍；
    - 已知问题；
    - 大致投入时间；
    - 如果继续开发两周，准备如何演进当前实现。
6. `AI_USAGE.md`，简要说明：
    - 使用了哪些 AI 工具；
    - AI 主要参与了哪些工作；
    - 哪些关键结果经过了人工验证；
    - 一个 AI 生成结果存在问题、你发现并修正它的例子。

不需要完成

- 完整注册和账号系统；
- 支付、订阅或虚拟货币；
- 管理后台；
- 角色市场或社区；
- 原生 iOS 或 Android 客户端；
- 模型训练或微调；
- 多角色、多章节或完整游戏内容；
- 大规模生产环境基础设施。

已有	github.com/FireTable/project-xiaochun · feature/interactive-scene-flow	
已有 已迭代	线上 xiaochun.firetable.tech；体验需用分支 feature/interactive-scene-flow(未合并 main)	
已有 已迭代	↑部分→已有 一行 pnpm i && pnpm dev → https://localhost:5185(自签名)；依赖已补齐	
已有 已迭代	↑无→已有 录屏已交付：README §1 附 4K/2K 两个 Telegram 公开频道链接	
已有 已迭代	录屏已演示文字/语音互动(README §1 自检已勾选)	
已有 已迭代	录屏已演示角色状态与画面变化(镜头/表情/场景)	
已有 已迭代	↑部分→已有 打断在聊天模式+补充视频演示	
已有 已迭代	录屏已演示 VRM 动画+EMAGE 手势	
已有	可演示 TTS 失败只出字幕、STT 熔断回落、LLM 超时兜底拍	
已有 已迭代	↑部分→已有 docs/coding-test/README.md 按模板 9 节全部填写	
已有 已迭代	README §2：mermaid 架构图+6 大模块职责	
已有 已迭代	↑部分→已有 README §3：多轮流程、打断检测、清理失效、迟到响应三道令牌	
已有 已迭代	↑部分→已有 README §4：zod 拍子协议示例+情绪/动作/镜头/事件清单	
已有 已迭代	README §5：LLM/STT/TTS/动画/第三方服务	
已有 已迭代	↑部分→已有 README §6：3 组选型取舍	
已有 已迭代	↑部分→已有 README §7：未完成能力/挑战/降级兜底	
已有 已迭代	↑无→已有 README §8：扣除睡眠与休息后的有效时长表，合计约 35.5h	
已有 已迭代	↑无→已有 README §9：动作管线(FootIK/全身多角度)、合并剧情与聊天、动作生成分支、LoRA 训练	
已有 已迭代	↑无→已有 docs/coding-test/AI_USAGE.md 按模板 4 节填写	
已有 已迭代	↑无→已有 Gemini 3.8 Flash / Grok+Grok Bot / MiniMax	
已有 已迭代	↑无→已有 编码/方案/测试/文档/审计核对的分工	
已有 已迭代	↑无→已有 实机验收+自动化门禁+逐条审计+线上验证	
已有 已迭代	↑无→已有 动作管线 preserveMotion 例子(ad3c0c9→7aab7f0→2d71fa2)；待用户确认	

如果某个能力没有完成，请在 README 中说明当前状态、遇到的问题以及下一步方案。一个范围清晰、能够稳定运行的版本即可。

已有
已迭代

↑无→已有 README §7 列出未完成能力、现状与下一步